

Allineamenti di sequenze: concetti e algoritmi



1

globine: α - β - mioglobina

Table 1

Hemoglobin		Myoglobin		Hemoglobin		Myoglobin	
α	β	α	β	α	β	α	β
1	Val	Val	77	1	Val	12	12
2	Leu	Leu	78	2	Leu	13	13
3	Ser	Ser	79	3	Ala	14	14
4	Pro	Pro	80	4	Leu	15	15
5	Ala	Glu (G)	81	5	Ala	16	16
6	Thr	Thr	82	6	Ala	17	17
7	Leu	Leu	83	7	Ala	18	18
8	Leu	Leu	84	8	Ala	19	19
9	Ala	Ala	85	9	Ala	20	20
10	Val	Val	86	10	Ala	21	21
11	Ala	Ala	87	11	Ala	22	22
12	Leu	Leu	88	12	Ala	23	23
13	Ala	Ala	89	13	Ala	24	24
14	Ala	Ala	90	14	Ala	25	25
15	Ala	Ala	91	15	Ala	26	26
16	Ala	Ala	92	16	Ala	27	27
17	Ala	Ala	93	17	Ala	28	28
18	Ala	Ala	94	18	Ala	29	29
19	Ala	Ala	95	19	Ala	30	30
20	Ala	Ala	96	20	Ala	31	31
21	Ala	Ala	97	21	Ala	32	32
22	Ala	Ala	98	22	Ala	33	33
23	Ala	Ala	99	23	Ala	34	34
24	Ala	Ala	100	24	Ala	35	35
25	Ala	Ala	101	25	Ala	36	36
26	Ala	Ala	102	26	Ala	37	37
27	Ala	Ala	103	27	Ala	38	38
28	Ala	Ala	104	28	Ala	39	39
29	Ala	Ala	105	29	Ala	40	40
30	Ala	Ala	106	30	Ala	41	41
31	Ala	Ala	107	31	Ala	42	42
32	Ala	Ala	108	32	Ala	43	43
33	Ala	Ala	109	33	Ala	44	44
34	Ala	Ala	110	34	Ala	45	45
35	Ala	Ala	111	35	Ala	46	46
36	Ala	Ala	112	36	Ala	47	47
37	Ala	Ala	113	37	Ala	48	48
38	Ala	Ala	114	38	Ala	49	49
39	Ala	Ala	115	39	Ala	50	50
40	Ala	Ala	116	40	Ala	51	51
41	Ala	Ala	117	41	Ala	52	52
42	Ala	Ala	118	42	Ala	53	53
43	Ala	Ala	119	43	Ala	54	54
44	Ala	Ala	120	44	Ala	55	55
45	Ala	Ala	121	45	Ala	56	56
46	Ala	Ala	122	46	Ala	57	57
47	Ala	Ala	123	47	Ala	58	58
48	Ala	Ala	124	48	Ala	59	59
49	Ala	Ala	125	49	Ala	60	60
50	Ala	Ala	126	50	Ala	61	61
51	Ala	Ala	127	51	Ala	62	62
52	Ala	Ala	128	52	Ala	63	63
53	Ala	Ala	129	53	Ala	64	64
54	Ala	Ala	130	54	Ala	65	65
55	Ala	Ala	131	55	Ala	66	66
56	Ala	Ala	132	56	Ala	67	67
57	Ala	Ala	133	57	Ala	68	68
58	Ala	Ala	134	58	Ala	69	69
59	Ala	Ala	135	59	Ala	70	70
60	Ala	Ala	136	60	Ala	71	71
61	Ala	Ala	137	61	Ala	72	72
62	Ala	Ala	138	62	Ala	73	73
63	Ala	Ala	139	63	Ala	74	74
64	Ala	Ala	140	64	Ala	75	75
65	Ala	Ala	141	65	Ala	76	76
66	Ala	Ala	142	66	Ala	77	77
67	Ala	Ala	143	67	Ala	78	78
68	Ala	Ala	144	68	Ala	79	79
69	Ala	Ala	145	69	Ala	80	80
70	Ala	Ala	146	70	Ala	81	81
71	Ala	Ala	147	71	Ala	82	82
72	Ala	Ala	148	72	Ala	83	83
73	Ala	Ala	149	73	Ala	84	84
74	Ala	Ala	150	74	Ala	85	85
75	Ala	Ala	151	75	Ala	86	86
76	Ala	Ala	152	76	Ala	87	87
			153		Ala	88	88
			154		Ala	89	89
			155		Ala	90	90
			156		Ala	91	91
			157		Ala	92	92
			158		Ala	93	93
			159		Ala	94	94
			160		Ala	95	95
			161		Ala	96	96
			162		Ala	97	97
			163		Ala	98	98
			164		Ala	99	99
			165		Ala	100	100

Precoce esempio di
allineamento di sequenza:
globine (1961)



H.C. Watson and J.C. Kendrew,
"Comparison Between the
Amino-Acid Sequences of
Sperm Whale Myoglobin and of
Human Hæmoglobin." *Nature*
190:670-672, 1961.

2

L'allineamento di sequenze a coppie è un'operazione fondamentale in bioinformatica

- E' utilizzato per decidere se due proteine (o geni) sono correlate **strutturalmente** e **funzionalmente**
- Viene utilizzato per identificare i **domini** o **motivi** che sono condivisi tra le proteine
- E' alla base della ricerca con BLAST (prossime lezioni)
- Viene utilizzato anche per l'**analisi dei genomi e dei trascrittomi**

3

Allineamento a coppie: sequenze di proteine possono essere più informative del DNA

- le proteine sono **più informative** del DNA (20 vs 4 caratteri); molti aminoacidi condividono proprietà biofisiche
- I codoni sono **degenerati**: i cambiamenti in terza posizione spesso non alterano l'amminoacido che ne è specificato (mutazioni sinonime)
- le sequenze di proteine offrono un **più lungo tempo di "look-back"**
- le sequenze di DNA possono essere **tradotte** in proteine, e poi utilizzate negli allineamenti a coppie

4

		Second letter				
		U	C	A	G	
First letter	U	UUU } Phe UUC } UUA } Leu UUG }	UCU } UCC } Ser UCA } UCG }	UAU } Tyr UAC } UAA Stop UAG Stop	UGU } Cys UGC } UGA Stop UGG Trp	U C A G
	C	CUU } CUC } Leu CUA } CUG }	CCU } CCC } Pro CCA } CCG }	CAU } His CAC } CAA } Gln CAG }	CGU } CGC } Arg CGA } CGG }	U C A G
	A	AUU } AUC } Ile AUA } AUG Met	ACU } ACC } Thr ACA } ACG }	AAU } Asn AAC } AAA } Lys AAG }	AGU } Ser AGC } AGA } Arg AGG }	U C A G
	G	GUU } GUC } Val GUA } GUG }	GCU } GCC } Ala GCA } GCG }	GAU } Asp GAC } GAA } Glu GAG }	GGU } GGC } Gly GGA } GGG }	U C A G

5

Definizione: allineamento a coppie

Allineamento a coppie:

Il processo che allinea due sequenze per raggiungere livelli massimi di **identità** (e **conservazione**, nel caso di sequenze di amminoacidi) al fine di valutare il grado di similitudine e la possibilità di **omologia**.

6

Definizioni:

l'identità, la similitudine, la conservazione

Identità

La misura in cui due sequenze (di nucleotidi o amminoacidi) sono invarianti. (es. identità del 32% => 32 a.a. su 100 sono **ordinatamente** identici)

Conservazione

In una sequenza, modifiche in una specifica posizione di un amminoacido (o meno comunemente, di un nucleotide) che preservano le proprietà fisico-chimiche del residuo originale.

Similitudine

La misura in cui due sequenze (di nucleotidi o amminoacidi) sono correlate. Si basa su identità + conservazione.

7

Definizione: omologia

Omologia

Similitudine attribuita a **discendenti** da un **antenato comune**.

NOTA BENE:

- **OMOLOGIA** indica che due entità (es. 2 sequenze) hanno una stessa origine filogenetica, cioè derivano da un antenato comune. È un carattere **QUALITATIVO**.
- **SIMILITUDINE** indica che due entità (es. 2 sequenze), in relazione ad *un certo criterio* comparativo, hanno *un certo grado* di similitudine. È un carattere **QUANTITATIVO** (vedremo tra breve come definirla).

8

Definizione: omologia

Osservazioni:


- La **struttura** di una proteina **dipende della sua sequenza di a.a.** (concetto alla base del Protein Folding).
- La **struttura** determina la **funzione** molecolare della proteina.
- Se una sequenza proteica è **conservata** durante l'evoluzione ed è quindi presente in organismi diversi (famiglia di proteine) è ragionevole assumere che le funzioni che svolge siano simili o per lo meno correlate.

Passi per **predizione di funzione**:

- Identificazione delle **proteine di una famiglia** (evolute da un progenitore comune -> sequenza di a.a. abbastanza simile.)
- Identificazione degli a.a. che svolgono un ruolo **strutturale o funzionale** analogo (allineamento).


9

Esempio: l'emoglobina




10

ESEMPIO 1: catena β dell'emoglobina e mioglobina «si somigliano»



11

ESEMPIO 2: catena α e β dell'emoglobina umana



Le zone con indel nelle sequenze sono strutturalmente dissimili

12

Definizioni: due tipi di omologia

Ortologhi


sequenze omologhe in **diverse specie** che derivano, tramite la **speciazione**, da un gene ancestrale comune. La funzione **può essere o non essere simile**.

Paraloghi


sequenze omologhe **all'interno di una singola specie** sorte dalla **duplicazione genica**.

13

Ortologhi e paraloghi sono spesso rappresentati in un albero singolo



Fonte: NCBI




Ortologhi:
membri di una
famiglia di geni
(proteine)
in vari organismi.

Questo albero
mostra gli
**ortologhi della
globina**

È possibile visualizzare queste sequenze a www.bioinfbook.org (documento 3.1)

15

Paraloghi: i membri di una famiglia di geni (proteine) all'interno di una specie. Questo albero mostra i **paraloghi della globina umana**



16

CONFRONTARE DUE SEQUENZE:

Come posso trasformare una stringa in un'altra?

Un modo semplice per capirlo è *allineare* le due stringhe:

ESEMPIO

1 LA CASA NUOVA

2 LA CASSA VUOTA

1 LA CA-SA NUOVA

2 LA CASSA VUOTA

oppure

1 LA CA-SA -NUOVA

2 LA CASSA V-UOTA

Nel secondo caso c'è un'operazione in più

17


- Il *numero minimo* di operazioni necessarie per allineare due sequenze ne misura la **distanza**
- La Natura dispone di varie operazioni per trasformare un oggetto nell'altro (mutazioni, indel...).
- L'evoluzione sceglie la via piu' breve (principio di **massima parsimonia**); cio' si manifesta tramite l'analisi dell'allineamento

Dobbiamo avere chiari i concetti di **match** (residui appaiati), **mismatch** (sostituzioni) e **gap** (indel)

18


Come identificare le zone di somiglianza locale tra due sequenze? Un modo semplice: la **matrice a punti** (dot plot)

Confrontiamo la stringa con se stessa (**autoconfronto**):
1. Mettiamo una x per ogni identità



... piuttosto banale. Cambiamo la seconda stringa

19




Abbiamo effettuato un'**inversione**. Il pattern delle diagonal lo mostra chiaramente: la diagonale principale si spezza ma porzioni delle stringhe sono identiche


20

Possiamo individuare facilmente alcuni patterns mediante le matrici a punti (la prima stringa in alto resta immutata):


Inversione di parole



Ripetizione di parole



Delezione di caratteri



21

Se pero' allineamo sequenze di acidi nucleici (solo 4 lettere) il "segnale" di similitudine e' mascherato dal grande **rumore di fondo**

Servono **FILTRI** per ridurre il rumore.


Una semplice osservazione: le **zone** delle sequenze piu' simili localmente si distribuiscono su **diagonali**; le altre somiglianze *puntiformi* si distribuiscono *casualmente*

Allora, e' meglio confrontare le sequenze non per singole posizioni, ma per interi segmenti (**FINESTRE**)

Potremmo usare delle **finestre scorrevoli**

22

ESEMPIO: confrontiamo una finestra di 5 residui in una seq con una finestra di 5 residui nell'altra. Confronto tutte le finestre (facendole scorrere), e metto una * al centro della finestra solo se ho un match totale




In generale: si fa scorrere una finestra alla volta

Generalizzando la procedura:

1. Definiamo la posizione di una casella (x,y)
2. Fissiamo il centro della finestra, di raggio g
3. La lunghezza della finestra e' dunque:

$$L = 2g + 1$$
4. Il numero N di residui identici in quella finestra e' allora:



$$N(x,y) = \sum_{h=-g}^{+g} S(x+h,y+h)$$

$S=1$ se il carattere in $x+h$ e' identico a quello in $y+h$; altrimenti $S=0$

24

Questa regola e' pero' molto restrittiva. A noi interessa anche la *similitudine*, non solo l'identita'. Potremmo definire una soglia *s*, per cui:

- Se $N(x,y) > s$ mette un simbolo nella casella in posizione x,y

Dobbiamo quindi *misurare la similitudine*, e.g. tra aa o basi. Un esempio di *matrice di punteggio* (non di punti!!!) per seq di nucleotidi puo' essere:

Esempio: secondo la matrice di punteggio a sx, l'allineamento ha punteggio 8

	A	T	C	G
A	2	1	0	0
T	1	2	0	0
C	0	0	2	1
G	0	0	1	2

A	A	A	T	C	C	G	A	A
A	T	A	C	A	G	A	T	T
(2)	(+1)	+2	+0	+0	+1	+0	+1	+1

= 8

25

Misurata la similitudine, possiamo allora attribuire un nuovo punteggio al confronto fra due finestre:

$N(x,y)$ è il numero dei residui *simili*, ed e' la *media* dei punteggi delle *single coppie* prelevati dalla *matrice di punteggio* scelta:

$$N(x,y) = \sum_{h=-g}^{+g} S(x+h, y+h) / L$$

S ora dipende da quale matrice di punteggio scegliamo e dalla lunghezza della finestra.

Possiamo quindi essere un po' più "elastici" pur mantenendo la regola:

- Se $N(x,y) > s$ mette un simbolo nella casella in posizione x,y

s lo decide la matrice di punteggio (cioe' la *similitudine*)


26

In conclusione, la visualizzazione (ed il calcolo) di una matrice a punti dipende da:



1. La lunghezza *L* della finestra scorrevole scelta
2. Il metodo per misurare la similitudine $S(x,y)$
3. La soglia *s* per "marcare" la casella rispettiva

In pratica conviene fissare 2 parametri e variare il terzo per rendere le zone di similitudine piu' evidenti. Molti programmi fanno questo. Es. DOTTER/Dotlet assegna un colore dipendentemente da S

Esempio: autoconfronto della Calmodulina umana visualizzato con DOTTER



Proiettando le diagonali sulla seq identifico motivi simili



NOTA: Analogamente all'identità di sequenza, che si può misurare in percentuale (%), *anche la similitudine, una volta quantificata, si può misurare in %*

S_1 e S_2 sono due sequenze lunghe, rispettivamente, L_1 ed L_2 . Scelta L_1 come riferimento si ha:

$$\text{Sequence identity (s.i.)} = \left(\frac{\# \text{matches}}{L_1} \right) * 100$$

Ottenuto allineando S_1 con S_2 ed attribuendo il punteggio ottenuto dalla matrice di score

$$\text{Sequence similarity: (s.s.)} = \left(\frac{S_1 \text{ vs. } S_2 \text{ similarity score}}{S_1 \text{ vs. } S_1 \text{ identity score}} \right) * 100$$

Ottenuto allineando S_1 con se stessa ed attribuendo il punteggio ottenuto dalla matrice di score

NOTA: se sono presenti indel, a denominatore metto la *lunghezza dell'allineamento* (compresi gli indel), e non la lunghezza originale della seq

8

ALGORITMI DINAMICI DI ALLINEAMENTO

I dot plots non tengono in considerazione gli indel. Occorrono altri algoritmi che, passo a passo e seguendo una certa direzione, trovino l'allineamento con:


- *Maggior numero di simboli identici*
- *Minor numero di indel* (sfavorite evolutivamente)

ESEMPIO: proviamo tutte le combinazioni da sx a dx, riempiendo una **colonna** alla volta (qui mostriamo solo i primi 3 residui!!)

Stabiliamo inoltre i **punteggi**:
-1 per indel
0 per residui diversi
+1 per residui identici

NOTA:
Alcuni allineamenti parziali (in grigio) hanno il punteggio maggiore

Sequenze da allineare




29

Il numero delle combinazioni possibili è molto grande, specie per sequenze lunghe.

- Nel 1970 **NEEDLEMAN e WUNSCH** creano un algoritmo, poi migliorato ed esteso. Noi analizziamo l'originale.

Il concetto: distribuiamo le due sequenze in una *matrice*. Il possibile allineamento tra le due identifica un **percorso** che unisce le caselle dei residui appaiati



Due possibili allineamenti:

linea chiara

A	D	C	N	Y	R	Q	C	L	C	R	P	M
A	Y	C	Y	N	R	-	C	K	C	R	D	P

linea scura

A	D	C	N	Y	-	R	Q	C	L	C	R	-	P
A	Y	C	-	Y	N	R	-	C	K	C	R	30	P

Regole pratiche:

1. Il percorso ha una **direzione** e procede solo in avanti (**NON** si torna **indietro!**)
2. Occorre trovare il percorso con il **>** numero di aa identici e il **<** numero di indel
3. Occorre anche tener conto della **similitudine** fra aa (significato evolutivo)
4. **IMPORTANTE:** un allineamento ottimale è sempre composto da **suballineamenti ottimali** (cioè: togliendo uno ad uno i residui dal fondo, l'allineamento deve restare ottimale, per poter ricostruire il percorso a ritroso)

31

Torniamo all'esempio e procediamo per steps


1. **INIZIALIZZAZIONE** della matrice: regola molto semplice; 1 se identici, 0 altrimenti. N.B. ora (x,y) identifica: (residuo in colonna, residuo in riga) (**N.B. dopo aver trattato le matrici di score potremo normalizzare diversamente...**)

		1	2	3	4	5	6	7	8	9	10	11	12	13
		A	D	C	N	Y	R	Q	C	L	C	R	P	M
1	A	1	0	0	0	0	0	0	0	0	0	0	0	0
2	Y	0	0	0	0	1	0	0	0	0	0	0	0	0
3	C	0	0	1	0	0	0	0	1	0	1	0	0	0
4	Y	0	0	0	0	1	0	0	0	0	0	0	0	0
5	N	0	0	0	1	0	0	0	0	0	0	0	0	0
6	R	0	0	0	0	0	1	0	0	0	0	1	0	0
7	C	0	0	1	0	0	0	0	1	0	1	0	0	0
8	K	0	0	0	0	0	0	0	0	0	0	0	0	0
9	C	0	0	1	0	0	0	0	1	0	1	0	0	0
10	R	0	0	0	0	0	1	0	0	0	0	1	0	0
11	D	0	1	0	0	0	0	0	0	0	0	0	0	0
12	P	0	0	0	0	0	0	0	0	0	0	0	1	0

32


2. Partiamo da (1,1) (in alto a sx: la direzione è importante!!):
(1,1) -> (2,2)

L'unico percorso possibile è questo: per "ricordarmelo" sommo il valore della cella (1,1) a quello della cella (2,2) da matrice inizializzata




3. Prossimo step: **verso (2,3)**

Ci sono due possibili percorsi, corrispondenti a due diversi allineamenti: **scelgo quello con punteggio finale maggiore**, sempre sommando casella precedente a (2,3)




33

4. Procediamo analogamente: ad esempio, **verso (4,4)**




34

... e oltre, ad es. **verso (4,5)**: qui il nuovo punteggio sarà 3



35

Alla fine arriveremo fino all'ultima casella in basso a dx:



Da essa possiamo spostarci a ritroso poiché abbiamo memorizzato i migliori punteggi dalle caselle precedenti. Abbiamo così determinato il miglior allineamento:

A D C N Y R Q C L C R P M
A Y C Y N R C K C R D P
1 0 1 0 1 0 1 0 1 0 1 1 0 1 0

Qui il punteggio totale coincide con il numero di residui identici
 $8/15 = 0.53 = 53\%$ identità di sequenza

In termini più formali, la casella (i,j) avrà lo score $S(i,j)$ ricalcolato a partire dalla matrice di inizializzazione in questo modo:

	A	D	C	N	Y	R	Q	C	L	C	R	P	M
A	1	0	0	0	0	0	0						
Y	0	1	1	1	2	1	1						
C	0	1	2	1	1	2	2						
Y	0	0	1	2	3	2	2						
N	0	0	1	2	2	3	3						
R	0	1	1	2	2	4	3						
C	0	1	1	2	2	4	3						
K	0	1	1	2	2	4	3						
C	0	1	1	2	2	4	3						
R	0	1	1	2	2	4	3						
D	0	1	1	2	2	4	3						
P	0	1	1	2	2	4	3						

$$S(i,j) = \left\{ s(a_i, b_j) + \max[S(i-1, j-1), S(i-k, j-1), S(i-1, j-l)] \right\}$$

Dovremmo però trovare un modo più efficace di inizializzare la matrice tenendo conto della *similarità fra aa*

37

Needleman-Wunsch: *programmazione dinamica*

NW garantisce l'*ottimalità dell'allineamento*, anche se l'algoritmo non calcola tutti i possibili allineamenti.

E' un esempio di un algoritmo di programmazione dinamica: un percorso ottimale (allineamento) è identificato dall'estensione graduale di *sottopercorsi localmente ottimali*.

Dunque, una *serie di decisioni* è effettuata ad ogni passo dell'allineamento per trovare la coppia di residui con il miglior punteggio per quel passo.

Needleman-Wunsch: online c/o NCBI

L'algoritmo di Needleman-Wunsch è disponibile presso EBI:

http://www.ebi.ac.uk/Tools/psa/emboss_needle/

EBI ospita molti tools per allineamenti locali e globali di sequenze (Pairwise Sequence Alignment). Date un'occhiata al sito:

<http://www.ebi.ac.uk/Tools/psa/>

EMBL-EBI European Bioinformatics Institute

Get Nucleotide sequences for

EBI Home About EBI Groups Services Toolbox Databases Downloads Submissions

SEQUENCE ANALYSIS

• Help Index
• General Help
• Formats
• Gaps
• Matrix
• References
• EMBOS-Align Help

EMBOSS Pairwise Alignment Algorithms

This tool is used to compare 2 sequences. When you want an alignment that covers the whole length of both sequences, use *needle*. When you are trying to find the best region of similarity between two sequences, use *water*.

Method		Gap Open
EMBOSS::needle (global)		10.0
Gap Extend	Molecule	Matrix
0.5	Protein	Blossum62

Sequence 1: paste Sequence in any format OR upload a file:

Query:
globina beta (NP_000509)
alfa globina (NP_000549)

Seq. 1 Upload a file:

Sequence 2: paste Sequence in any format OR upload a file:

```
#####
# Program: needle
# Rundate: Tue Aug 22 16:29:58 2006
# Align_format: srspair
# Report_file: /ebi/extserv/old-work/needle-20060822-16295743003385.output
#####
```

```
#-----
```

```
#
# Aligned_sequences: 2
# 1: EMBOSS_001
# 2: EMBOSS_001
# Matrix: EBLOSUM62
# Gap_penalty: 10.0
# Extend_penalty: 0.5
#
# Length: 149
# Identity: 65/149 (43.6%)
# Similarity: 90/149 (60.4%)
# Gaps: 9/149 ( 6.0%)
# Score: 292.5
#
#-----
```

EMBOSS_001	1	MVHLTPEEKSAVTALWGKV--NVDEVGGEALGRLLVVYPWTQRFFESFGD	48
		: : : : : : : : : : : : : : : :	
EMBOSS_001	1	MV-LSPADKTNVKAAGKVGAGAHAGEYGAEALERMFLSFPTTKTYFPHF-D	48
EMBOSS_001	49	LSTPDVVMGNPKVKAHGKKVLGAFSDGLAHLNKGTFATLSELHCDKLH	98
		: : : : : : : : : : : : : : : : : : : : :	
EMBOSS_001	49	LS-----HGSAQVKGHGKKVADALTNAVAHVDDMPNALSALSDLHAHKLR	93
EMBOSS_001	99	VDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAAYQKVAGVANALAHKYH	147
		: : : : : : : : : : : : : : : : : : : : :	
EMBOSS_001	94	VDPVNFKLLSHCLLVTLAAHLPAEFTPAVHASLDKFLASVSTVLTSKYR	142