

## - Allineamenti di sequenze 2 - Matrici di Sostituzione



1

Un problema dell'algoritmo di Needleman-Wunsch: non si tiene conto della penalizzazione delle indel.

L'algoritmo di **WATERMAN-SMITH** (1976) introduce una **funzione di penalizzazione** delle indel, per migliorare l'algoritmo NW:

• serve un sistema di pesatura delle indel, ad esempio:

$$w(k) = g + e(k-1)$$

Il peso  $w$  di una indel di lunghezza  $k$  dipende dalla penalizzazione per l'apertura di una singola indel ( $g$ ) e dalla penalizzazione per l'allungamento ( $e$ )

2

Nella pratica l'algoritmo procede in questo modo:

1. **Inserisce una riga e una colonna 0-ime** alla matrice di inizializzazione (calcolata ad esempio partire da BLOSUM o PAM che vedremo, ecco perché non ha solo 0 o 1)

|    |   | A D C N Y R Q C L C R P M |     |     |     |     |     |     |     |     |     |     |     |     |
|----|---|---------------------------|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
|    |   | 1                         | 2   | 3   | 4   | 5   | 6   | 7   | 8   | 9   | 10  | 11  | 12  | 13  |
| 1  | A | 0                         | -12 | -16 | -20 | -24 | -28 | -32 | -36 | -40 | -44 | -48 | -52 | -56 |
| 2  | Y | -12                       | 2   | 0   | -2  | 0   | -3  | -2  | 0   | -2  | -2  | -2  | -2  | -1  |
| 3  | C | -16                       | -3  | -4  | 0   | -2  | 10  | -4  | 0   | -1  | 0   | -4  | -5  | -2  |
| 4  | N | -20                       | -2  | -5  | 12  | -4  | 0   | -4  | -5  | 12  | -6  | 12  | -4  | -3  |
| 5  | R | -24                       | -3  | -4  | 0   | -2  | 10  | -4  | 0   | -1  | 0   | -4  | -5  | -2  |
| 6  | Q | -28                       | 0   | 2   | -4  | 2   | -2  | 0   | 1   | -4  | -3  | -4  | 0   | -1  |
| 7  | C | -32                       | -2  | -1  | -4  | 0   | 4   | 6   | 1   | -4  | -3  | -4  | -3  | -5  |
| 8  | L | -36                       | -2  | -5  | 12  | -4  | 0   | -4  | -5  | 12  | -6  | 12  | -4  | -3  |
| 9  | C | -40                       | -1  | 0   | -5  | 1   | -4  | 3   | 1   | -5  | -3  | -5  | 3   | -1  |
| 10 | R | -44                       | -2  | -5  | 12  | -4  | 0   | -4  | -5  | 12  | -6  | 12  | -4  | -3  |
| 11 | P | -48                       | -2  | -1  | -4  | 0   | -4  | 6   | 1   | -4  | -3  | -4  | 6   | 0   |
| 12 | D | -52                       | 0   | 4   | -5  | 2   | -4  | -1  | 2   | -5  | -4  | -5  | -1  | -3  |
| 13 | M | -56                       | 1   | -1  | -3  | -1  | -5  | 0   | 0   | -3  | -3  | -3  | 0   | 6   |


Valori iniziali presi da PAM250 (check!!)

Nella riga e colonna ombreggiate è sviluppata la **funzione di penalizzazione**:  
 $w(k) = -12 - 4(k-1)$

La riga e la colonna 0-ime contengono il **punteggio che la sequenza avrebbe se allineata a una delezione lunga fino alla cella corrispondente**

3

2. Tiene conto dei possibili modi per arrivare alla casella  $(i,j)$ . Il suo punteggio  $S(i,j)$  dipende da essi:



- a) Mi muovo in **diagonale**: no indel e punteggio dato da: punteggio della casella di partenza + punteggio della casella  $(i,j)$  secondo la matrice di inizializzazione (come in NW)
- b) Mi muovo in **verticale o orizzontale**: inserisco indel nella sequenza  $i$  e  $j$ . Il punteggio sarà dato da: punteggio della casella di partenza – funzione di penalizzazione  $w(k)$  ( $k$  è la lunghezza della indel)
- c) Scelgo alla fine il **percorso che dà il punteggio migliore**

4


## Waterman-Smith: online c/o EBI

L'algoritmo di Smith-Waterman per allineamenti locali è disponibile presso EBI:

[http://www.ebi.ac.uk/Tools/psa/emboss\\_water/](http://www.ebi.ac.uk/Tools/psa/emboss_water/)

## Allineamento: globale vs locale

- L'allineamento **globale** (NW e SW visto finora) si estende da un capo all'altro di ogni sequenza.
- L'allineamento **locale** trova le **regioni (sottosequenze)** di due sequenze **che si allineano in modo ottimale**.



Qui l'allineamento globale maschera la corrispondenza tra zone somiglianti


- SW si può modificare per renderlo capace di calcolare **allineamenti locali**: basta introdurre fra i casi possibili  $S(i,j)=0$  nel caso in cui nell'allineamento globale fosse negativo

### ESEMPIO 1:

L'allineamento fra una flavoemoproteina (con un dominio di tipo emoglobinico) e la catena A dell'emoglobina umana

- **globale**: più difficile notare quantitativamente la similitudine

- **locale**: più apparente



**ESEMPIO 2:** SW locale:dopo aver ricalcolato la matrice cerco la **cella con il valore massimo assoluto** e parto da lì.

Gli stessi due peptidi di prima, allineati con Waterman-Smith globale e locale danno luogo a matrici ed allineamenti diversi. Partendo dalle caselle con score maggiore il percorso **a ritroso** individua allineamenti differenti (non sempre AL è sottoinsieme di AG)

|   | A   | D   | C   | N   | Y   | R   | Q   | C   | L   | G   | R   | P   | M   |
|---|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| A | 0   | -12 | -16 | -20 | -24 | -28 | -32 | -36 | -40 | -44 | -48 | -52 | -56 |
| D | -12 | 2   | -10 | -14 | -18 | -22 | -26 | -30 | -34 | -38 | -42 | -46 | -50 |
| C | -16 | -10 | 2   | -10 | -16 | -8  | -20 | -24 | -28 | -32 | -36 | -40 | -44 |
| N | -20 | -14 | -14 | 10  | -2  | -6  | -10 | -14 | -12 | -22 | -20 | -30 | -34 |
| Y | -24 | -18 | -18 | -2  | 8   | 8   | -4  | -8  | -12 | -13 | -20 | -24 | -28 |
| R | -28 | -22 | -16 | -6  | 0   | 6   | 8   | -3  | -8  | -12 | -16 | -20 | -24 |
| Q | -32 | -26 | -23 | -10 | -6  | -4  | 12  | 9   | -3  | -7  | -11 | -10 | -19 |
| C | -36 | -30 | -30 | -11 | -12 | -6  | 0   | 7   | 21  | 9   | 5   | 1   | -3  |
| L | -40 | -34 | -30 | -18 | -10 | -14 | -3  | 1   | 9   | 18  | 6   | 8   | 0   |
| G | -44 | -38 | -38 | -18 | -20 | -10 | -8  | -8  | 13  | 6   | 30  | 18  | 14  |
| R | -48 | -42 | -39 | -26 | -18 | -22 | -4  | -7  | 1   | 10  | 18  | 36  | 24  |
| P | -52 | -46 | -38 | -30 | -24 | -22 | -16 | -2  | -3  | -2  | 14  | 24  | 35  |
| M | -56 | -50 | -47 | -34 | -31 | -29 | -20 | -14 | -5  | -6  | 10  | 20  | 30  |

|   | A   | D   | C   | N   | Y   | R   | Q   | C   | L   | G   | R   | P   | M   |
|---|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| A | 0   | -12 | -16 | -20 | -24 | -28 | -32 | -36 | -40 | -44 | -48 | -52 | -56 |
| D | -12 | 2   | 0   | 0   | 0   | 0   | 0   | 0   | 0   | 0   | 0   | 0   | 0   |
| C | -16 | 0   | 0   | 0   | 0   | 10  | 0   | 0   | 0   | 0   | 0   | 0   | 0   |
| N | -20 | 0   | 0   | 12  | 0   | 0   | 6   | 0   | 12  | 0   | 12  | 0   | 0   |
| Y | -24 | 0   | 0   | 0   | 10  | 10  | 0   | 2   | 0   | 11  | 0   | 8   | 0   |
| R | -28 | 0   | 2   | 0   | 2   | 8   | 10  | 1   | 0   | 0   | 7   | 0   | 7   |
| Q | -32 | 0   | 0   | 0   | 0   | 0   | 14  | 11  | 0   | 0   | 0   | 13  | 1   |
| C | -36 | 0   | 0   | 12  | 0   | 0   | 2   | 9   | 23  | 11  | 12  | 3   | 10  |
| L | -40 | 0   | 0   | 0   | 13  | 1   | 3   | 3   | 11  | 20  | 8   | 15  | 3   |
| G | -44 | 0   | 0   | 12  | 1   | 13  | 1   | 0   | 15  | 8   | 32  | 20  | 16  |
| R | -48 | 0   | 0   | 0   | 12  | 1   | 19  | 7   | 3   | 12  | 20  | 38  | 26  |
| P | -52 | 0   | 4   | 0   | 2   | 8   | 7   | 21  | 9   | 5   | 16  | 26  | 37  |
| M | -56 | 0   | 0   | 1   | 0   | 0   | 8   | 9   | 18  | 6   | 12  | 22  | 32  |

ALLINEAMENTO WS-GLOBALE

A D C N Y R Q C L C R P M  
A Y C - Y N R C K C R D P

ALLINEAMENTO WS-LOCALE

Y R Q C L C R  
Y N R C K C R

In conclusione:

- L'allineamento **locale** è quasi sempre utilizzato per il ricerche **su database** (tramite **BLAST**). E 'utile per trovare domini (o regioni limitate di omologia) all'interno di sequenze.
- **Smith e Waterman** (1981) hanno risolto il problema dell'allineamento locale **ottimale** di sequenze.
- Altri metodi (BLAST, FASTA) sono più veloci ma meno accurati. Li vedremo in seguito
- In ogni caso, qualunque metodo di allineamento si scelga esso fornirà un punteggio **S** all'allineamento. **Ricordiamo sempre che lo score S dipende dal metodo di allineamento e non è assoluto!**

9

## Significatività statistica di un allineamento

### DOMANDA:

Ho allineato due sequenze A e B, ottenuto il punteggio S. Come posso capire se sono omologhe? **Che probabilità ho di trovare il punteggio S "per caso"?**


Il problema è più facilmente risolvibile per gli allineamenti locali, e meno per quelli globali.

Vediamo la procedura per questi ultimi

10


### **SIGNIFICATIVITA' ALLINEAMENTO GLOBALE: lo Z score**

- la seq **A** è mantenuta fissa; la **B** è "anagrammata" **n** volte ed ogni volta globalmente allineata ad A, calcolando lo score  $S_i$  per l'allineamento  $i$




- $S_i$  si distribuisce su una curva di cui si calcola la media  $\mu$  e la deviazione standard  $\sigma$ . Si definisce allora la distanza Z del punteggio S dell'allineamento dalla media in termini di dev. standard:

$$Z = \frac{S - \mu}{\sigma}$$



Area che dà la probabilità di ottenere per caso  $x \geq S$



- Uno **Z-score 0** = significa che la somiglianza osservata **non è migliore** rispetto alla **media di permutazioni casuali** della sequenza, e può anche essere casuale.

- Problema con Z-score: si assume una distribuzione normale, ma ciò può non esser corretto. Perciò Z deve essere considerato come una soglia di significatività.

12

## SIGNIFICATIVITA' ALLINEAMENTO LOCALE

Teoria abbastanza complessa, sviluppata da Karlin e Altschul partendo da questa osservazione:

Date due sequenze casuali, di lunghezza  $m$  ed  $n$ , il *numero atteso*  $E$  di *sottosequenze allineate localmente senza indel* che ottengono un punteggio  $S \geq x$  è:

$$E(S \geq x) = Kmne^{-\lambda x}$$


$m, n$ : lunghezze delle due sequenze  
 $K$ : dipende dalla matrice di punteggio  
 $\lambda$ : dipende dalla composizione aa

13

Dalla definizione di  $E$  si può calcolare la probabilità di osservare un allineamento locale con punteggio  $S \geq x$ :

$$p(S \geq x) = 1 - \exp(Kmne^{-\lambda x})$$

Distribuzione del valore estremo o di Gumbel: è diversa dalla gaussiana



### In pratica:

- allineamo localmente due seq
- otteniamo il punteggio  $x$
- calcoliamo  $p(S \geq x)$ , la *probabilità di ottenere un punteggio maggiore di  $x$  nell'ipotesi: le due seq NON sono omologhe*
- se  $p <$  soglia (es.  $0.01 = 1\%$ ) *siamo confidenti* che siano omologhe
- **SEMPRE:** serve *significatività BIOLOGICA* oltre che statistica

14


## MATRICI DI PUNTEGGIO

Abbiamo già visto che per dare un punteggio a un allineamento dobbiamo *misurare la similitudine* fra aa.

Usiamo perciò *matrici di punteggio* o *di sostituzione*: saranno matrici  $20 \times 20$ . Sono *matrici simmetriche*:  $A \rightarrow B = B \rightarrow A$  (non sappiamo evolutivamente chi si è trasformato dei due)

15

## Come quantificare la somiglianza degli aminoacidi?



Difficile stabilire criteri oggettivi per le somiglianze fisico-chimiche degli amino acidi. Non è possibile sapere a priori quali delle varie caratteristiche fisico-chimiche sono più importanti per le proteine






## PAM: Point Accepted Mutation

### Mutazione puntuale accettata.

- ✓ E' l'evento in cui il DNA subisce una **mutazione** che produce il cambiamento di un aminoacido
- ✓ Tale mutazione diviene **prevalente** in una specie

Dayhoff ha osservato famiglie di sequenze identiche all'**85%** (omologhe e molto simili). Le ha allineate e ha creato alberi di sequenze in cui ha dedotto le sequenze dei progenitori.



**Piccoli passi evolutivi**, per osservare l'evoluzione e dedurne le caratteristiche.

## Matrici PAM: le point accepted mutations

Le matrici PAM sono basate su **allineamenti globali** di proteine strettamente correlate.

Il **PAM1** è la matrice calcolata dal confronto di sequenze con non più di 1% di divergenza. **Ad un intervallo evolutivo di PAM1, un cambiamento si è verificato su una lunghezza di 100 aminoacidi.**

Altre matrici PAM sono estrapolate da PAM1 (PAM1 non ha utilità pratica). Per **PAM250**, 250 sostituzioni si sono verificate tra due proteine su una lunghezza di 100 aminoacidi, nel **passo evolutivo che essa rappresenta.**

**NOTA BENE:** Tutti i dati PAM provengono da proteine strettamente correlate (> 85% di identità degli aminoacidi).

## Dayhoff: 34 superfamiglie di proteine

### Proteina PAMs per 100 milioni di anni

|                            |    |
|----------------------------|----|
| Ig kappa chain             | 37 |
| Kappa casein               | 33 |
| luteinizing hormone b      | 30 |
| lactalbumin                | 27 |
| complement component 3     | 27 |
| epidermal growth factor    | 26 |
| proopiomelanocortin        | 21 |
| pancreatic ribonuclease    | 21 |
| haptoglobin alpha          | 20 |
| serum albumin              | 19 |
| phospholipase A2, group IB | 19 |
| prolactin                  | 17 |
| carbonic anhydrase C       | 16 |
| Hemoglobin α               | 12 |
| Hemoglobin β               | 12 |

## Dayhoff: 34 superfamiglie di proteine

### Proteina PAMs per 100 milioni di anni

|                         |    |
|-------------------------|----|
| Ig kappa chain          | 37 |
| Kappa casein            | 33 |
| luteinizing hormone b   | 30 |
| lactalbumin             | 27 |
| complement component 3  | 27 |
| epidermal growth factor | 26 |
| proopiomelanocortin     | 21 |
| pancreatic ribonuclease | 21 |

human (NP\_005203) versus mouse (NP\_031812)

Score = 57.8 bits (138), Expect = 3e-07  
Identities = 39/118 (33%), Positives = 61/118 (51%), Gaps = 2/118 (1%)

Query 1 MKSFLLVNALALTLPLAVEVQKQKPAACHENDERPFYQKTAPYVPMYVFNNSYPYGT 60  
M++F++V+N LALTLPLFLA E+QN E ++ ++ Y P+ V N + Y  
Sbjct 2 MRNFIVVMNIALALTLPLFLAAEIQNPDSNCRGEKNDIVYDEQRVLVTPVRSVLN-FNQYEP 60

Query 61 NLYQRPAI-AINNPPYPRTYANFAVVRPHAQIPQRQYLPNSHPPTVRLPNLHPSF 117  
N Y RP++ A +PY+ ++R A I + Q +PN V +PSF  
Sbjct 61 NYHYRPSLPATASPYMYPLVRLLLRSPAPISKWQSMFNPQSGVFPYAIINPSPF 118

## Dayhoff: 34 superfamiglie di proteine

### Proteine PAMs per 100 milioni di anni

|                               |     |
|-------------------------------|-----|
| apolipoprotein A-II           | 10  |
| lysozyme                      | 9.8 |
| gastrin                       | 9.8 |
| myoglobin                     | 8.9 |
| nerve growth factor           | 8.5 |
| myelin basic protein          | 7.4 |
| thyroid stimulating hormone b | 7.4 |
| parathyroid hormone           | 7.3 |
| parvalbumin                   | 7.0 |
| trypsin                       | 5.9 |
| insulin                       | 4.4 |
| calcitonin                    | 4.3 |
| arginine vasopressin          | 3.6 |
| adenylate kinase 1            | 3.2 |

## Dayhoff: 34 superfamiglie di proteine

### Proteine PAMs per 100 milioni di anni

|                                     |     |
|-------------------------------------|-----|
| triosephosphate isomerase 1         | 2.8 |
| vasoactive intestinal peptide       | 2.6 |
| glyceraldehyde phosph. dehydrogease | 2.2 |
| cytochrome c                        | 2.2 |
| collagen                            | 1.7 |
| troponin C, skeletal muscle         | 1.5 |
| alpha crystallin B chain            | 1.5 |
| glucagon                            | 1.2 |
| glutamate dehydrogenase             | 0.9 |
| histone H2B, member Q               | 0.9 |
| ubiquitin                           | 0   |

### Allineamento a coppie di ubiquitine: umana (NP\_005203) vs murina (NP\_031812)

Score = 1316 bits (3407), Expect = 0.0  
Identities = 681/685 (99%), Positives = 682/685 (99%), Gaps = 0/685 (0%)

```

Query 1  MQIFVKLTGKTTITLEVEPSDTIENVKAKIQDKEGIPPDQQLIFAGKQLEDGRTLSQYN 60
Sbjct 1  MQIFVKLTGKTTITLEVEPSDTIENVKAKIQDKEGIPPDQQLIFAGKQLEDGRTLSQYN 60

Query 61  IQKESTLHLVLRGGHQIFVKLTGKTTITLEVEPSDTIENVKAKIQDKEGIPPDQQLRI 120
Sbjct 61  IQKESTLHLVLRGGHQIFVKLTGKTTITLEVEPSDTIENVKAKIQDKEGIPPDQQLRI 120

Query 121  FAGKQLEDGRTLSQYNIQKESTLHLVLRGGHQIFVKLTGKTTITLEVEPSDTIENVKA 180
Sbjct 121  FAGKQLEDGRTLSQYNIQKESTLHLVLRGGHQIFVKLTGKTTITLEVEPSDTIENVKA 180

Query 181  KIQDKEGIPSDQQLIFAGKQLEDGRTLSQYNIQKESTLHLVLRGGHQIFVKLTGKTT 240
Sbjct 181  KIQDKEGIPSDQQLIFAGKQLEDGRTLSQYNIQKESTLHLVLRGGHQIFVKLTGKTT 240

Query 241  ITLEVEPSDTIENVKAKIQDKEGIPPDQQLIFAGKQLEDGRTLSQYNIQKESTLHLVLR 300
Sbjct 241  ITLEVEPSDTIENVKAKIQDKEGIPPDQQLIFAGKQLEDGRTLSQYNIQKESTLHLVLR 300

```

### Dayhoff e i numeri di “point accepted mutations”: Quali sostituzioni si verificano nelle proteine?

|   | A<br>Ala | R<br>Arg | N<br>Asn | D<br>Asp | C<br>Cys | Q<br>Gln | E<br>Glu | G<br>Gly |
|---|----------|----------|----------|----------|----------|----------|----------|----------|
| A |          |          |          |          |          |          |          |          |
| R | 30       |          |          |          |          |          |          |          |
| N | 109      | 17       |          |          |          |          |          |          |
| D | 154      | 0        | 532      |          |          |          |          |          |
| C | 33       | 10       | 0        | 0        |          |          |          |          |
| Q | 93       | 120      | 50       | 76       | 0        |          |          |          |
| E | 266      | 0        | 94       | 831      | 0        | 422      |          |          |
| G | 579      | 10       | 156      | 162      | 10       | 30       | 112      |          |
| H | 21       | 103      | 226      | 43       | 10       | 243      | 23       | 10       |

Conteggio delle mutazioni osservate (PAM1) Dayhoff (1978) p.346.

## La **mutabilità** relativa di amminoacidi

Quanto spesso mutano nelle proteine?

Definiamo la **Frequenza relativa di mutazione**

Alanina = 100 arbitrariamente

|            |            |     |    |
|------------|------------|-----|----|
| Asn        | 134        | His | 66 |
| Ser        | 120        | Arg | 65 |
| Asp        | 106        | Lys | 56 |
| Glu        | 102        | Pro | 56 |
| <b>Ala</b> | <b>100</b> | Gly | 49 |
| Thr        | 97         | Tyr | 41 |
| Ile        | 96         | Phe | 41 |
| Met        | 94         | Leu | 40 |
| Gln        | 93         | Cys | 20 |
| Val        | 74         | Trp | 18 |

## **Frequenze normalizzate** degli amminoacidi

Ogni quanto occorrono nelle proteine?

|     |      |            |      |
|-----|------|------------|------|
| Gly | 8.9% | Arg        | 4.1% |
| Ala | 8.7% | Asn        | 4.0% |
| Leu | 8.5% | Phe        | 4.0% |
| Lys | 8.1% | Gln        | 3.8% |
| Ser | 7.0% | Ile        | 3.7% |
| Val | 6.5% | His        | 3.4% |
| Thr | 5.8% | Cys        | 3.3% |
| Pro | 5.1% | Tyr        | 3.0% |
| Glu | 5.0% | <b>Met</b> | 1.5% |
| Asp | 4.7% | <b>Trp</b> | 1.0% |

- **blu**=6 codoni; **rosso**=1 codone
- Le frequenze  $f_i$  si sommano a 100

**ESEMPIO:** Prendiamo un allineamento multiplo di sequenze, ad esempio della deidrogenasi gliceraleide 3-fosfato:

**OSSERVAZIONE:**

le **colonne** di residui possono avere conservazione alta o bassa

|           |            |            |            |             |             |
|-----------|------------|------------|------------|-------------|-------------|
| fly       | GAKKVIISAP | SAD.APM..F | VCGVNLDAYK | PDMKVVSNAS  | CTNCLAPLA   |
| human     | GAKRVIISAP | SAD.APM..F | VMGVNHEKYD | NSLKIIISNAS | CTNCLAPLA   |
| plant     | GAKKVIISAP | SAD.APM..F | VVGVEHTYQ  | PNMDIVSNAS  | CTNCLAPLA   |
| bacterium | GAKKVVMTGP | SKDNTPM..F | VKGANFDKY  | AGQDIVSNAS  | CTNCLAPLA   |
| yeast     | GAKKVVITAP | SS.TAPM..F | VMGVNEEKYT | SDLKIVSNAS  | CTNCLAPLA   |
| archaeon  | GADKVLISAP | PKGDEPVKQL | VYGVNHDEYD | GE.DVVSNAS  | CTNSITPVA   |
| fly       | KVINDNFEIV | EGLMTTVHAT | TATQKTVDGP | SGKLWRDGRG  | AAQNIIPAST  |
| human     | KVIHDFNGIV | EGLMTTVHAI | TATQKTVDGP | SGKLWRDGRG  | ALQNIIPAST  |
| plant     | KVVHEEFGIL | EGLMTTVHAT | TATQKTVDGP | SMKDWRGGRG  | ASQNIIPSSST |
| bacterium | KVINDNFGII | EGLMTTVHAT | TATQKTVDGP | SHKDWRGGRG  | ASQNIIPSSST |
| yeast     | KVINDAFGIE | EGLMTTVHSL | TATQKTVDGP | SHKDWRGGRT  | ASGNIIPSSST |
| archaeon  | KVLDEEFGIN | AGQLTTVHAY | TGSQNLMDGP | NGKP.RRRRA  | AAENIIPST   |
| fly       | GAAKAVGKVI | PALNGKLTGM | AFRVPTPNVS | VVDLTVRLGK  | GASYDEIKAK  |
| human     | GAAKAVGKVI | PELNGKLTGM | AFRVPTANVS | VVDLTCRLEK  | PAKYDDIKKV  |
| plant     | GAAKAVGKVI | PELNGKLTGM | AFRVPTSNVS | VVDLTCRLEK  | GASYEDVKAA  |
| bacterium | GAAKAVGKVL | PELNGKLTGM | AFRVPTPNVS | VVDLTVRLEK  | AATYEQIKAA  |
| yeast     | GAAKAVGKVL | PELQKLTGM  | AFRVPTVDVS | VVDLTVLKNK  | ETTYDEIKKV  |
| archaeon  | GAAQAATEVL | PELEGKLDGM | AIRVPVPNGS | ITEFVVLDLD  | DVTESDVNA   |

## **Matrice PAM1 (probabilità)** di Dayhoff

Aminoacido originale

|   |          |          |          |          |          |          |          |          |          |          |
|---|----------|----------|----------|----------|----------|----------|----------|----------|----------|----------|
|   | A<br>Ala | R<br>Arg | N<br>Asn | D<br>Asp | C<br>Cys | Q<br>Gln | E<br>Glu | G<br>Gly | H<br>His | I<br>Ile |
| A | 98,6     | 0,02     | 0,09     | 0,01     | 0,03     | 0,08     | 0,17     | 0,21     | 0,02     | 0,06     |
| R | 0,01     | 99,1     | 0,01     | 0        | 0,01     | 10       | 0        | 0        | 10       | 0,03     |
| N | 0,04     | 0,01     | 98,2     | 0,36     | 0        | 0,04     | 0,06     | 0,06     | 0,21     | 0,03     |
| D | 0,06     | 0        | 0,42     | 98,5     | 0        | 0,06     | 0,53     | 0,06     | 0,04     | 0,01     |
| C | 0,01     | 0,01     | 0        | 0        | 99,7     | 0        | 0        | 0        | 0,01     | 0,01     |
| Q | 0,03     | 0,09     | 0,04     | 0,05     | 0        | 98,7     | 0,027    | 0,01     | 0,23     | 0,01     |
| E | 0,10     | 0        | 0,07     | 0,56     | 0        | 0,35     | 98,6     | 0,04     | 0,02     | 0,03     |
| G | 0,21     | 0,01     | 0,12     | 0,11     | 0,01     | 0,03     | 0,07     | 99,3     | 0,01     | 0        |
| H | 0,01     | 0,08     | 0,18     | 0,03     | 0,01     | 20       | 0,01     | 0        | 99,1     | 0        |
| I | 0,02     | 0,02     | 0,3      | 0,01     | 0,02     | 0,01     | 0,02     | 0        | 0        | 98,7     |

Aminoacido mutato

Ogni elemento della matrice mostra la probabilità che un amminoacido (in alto) venga **sostituito** da un altro amminoacido (a lato)




## Matrici di sostituzione

- Una matrice di sostituzione contiene valori **proporzionali alla probabilità che l'amminoacido  $i$  muti nell'amminoacido  $j$**  per tutte le coppie possibili di amminoacidi.
- Le matrici di sostituzione sono costruite assemblando un **campione ampio** e diversificato di **allineamenti a coppie** (o allineamenti multipli di sequenza) di amminoacidi.
- Le matrici di sostituzione dovrebbero **riflettere la probabilità reale di mutazione in un periodo di evoluzione**.
- I due principali tipi di matrici di sostituzione: **PAM** e **BLOSUM**.

## Idea: moltiplicare le matrici

Con  $(\text{PAM1})^n$  si può simulare il passaggio di  $n$  passi di evoluzione.



## Matrice di sostituzione PAM0 (*probabilità*) Ovvero: nulla cambia

Aminoacido originale

| PAM0              | A<br>Ala | R<br>Arg | N<br>Asn | D<br>Asp | C<br>Cys | Q<br>Gln | E<br>Glu | G<br>Gly |
|-------------------|----------|----------|----------|----------|----------|----------|----------|----------|
| Aminoacido mutato |          |          |          |          |          |          |          |          |
| A                 | 100%     | 0%       | 0%       | 0%       | 0%       | 0%       | 0%       | 0%       |
| R                 | 0%       | 100%     | 0%       | 0%       | 0%       | 0%       | 0%       | 0%       |
| N                 | 0%       | 0%       | 100%     | 0%       | 0%       | 0%       | 0%       | 0%       |
| D                 | 0%       | 0%       | 0%       | 100%     | 0%       | 0%       | 0%       | 0%       |
| C                 | 0%       | 0%       | 0%       | 0%       | 100%     | 0%       | 0%       | 0%       |
| Q                 | 0%       | 0%       | 0%       | 0%       | 0%       | 100%     | 0%       | 0%       |
| E                 | 0%       | 0%       | 0%       | 0%       | 0%       | 0%       | 100%     | 0%       |
| G                 | 0%       | 0%       | 0%       | 0%       | 0%       | 0%       | 0%       | 100%     |

Si sono verificati 0 passi di evoluzione: non è cambiato nulla!

## Matrice di sostituzione PAM2000 (*probabilità*) PAM1<sup>2000</sup>, ovvero: il caso

Aminoacido originale

| PAM $\infty$      | A<br>Ala | R<br>Arg | N<br>ASN | D<br>ASP | C<br>Cys | Q<br>Gln | E<br>Glu | G<br>Gly |
|-------------------|----------|----------|----------|----------|----------|----------|----------|----------|
| Aminoacido mutato |          |          |          |          |          |          |          |          |
| A                 | 8,7%     | 8,7%     | 8,7%     | 8,7%     | 8,7%     | 8,7%     | 8,7%     | 8,7%     |
| R                 | 4,1%     | 4,1%     | 4,1%     | 4,1%     | 4,1%     | 4,1%     | 4,1%     | 4,1%     |
| N                 | 4,0%     | 4,0%     | 4,0%     | 4,0%     | 4,0%     | 4,0%     | 4,0%     | 4,0%     |
| D                 | 4,7%     | 4,7%     | 4,7%     | 4,7%     | 4,7%     | 4,7%     | 4,7%     | 4,7%     |
| C                 | 3,3%     | 3,3%     | 3,3%     | 3,3%     | 3,3%     | 3,3%     | 3,3%     | 3,3%     |
| Q                 | 3,8%     | 3,8%     | 3,8%     | 3,8%     | 3,8%     | 3,8%     | 3,8%     | 3,8%     |
| E                 | 5,0%     | 5,0%     | 5,0%     | 5,0%     | 5,0%     | 5,0%     | 5,0%     | 5,0%     |
| G                 | 8,9%     | 8,9%     | 8,9%     | 8,9%     | 8,9%     | 8,9%     | 8,9%     | 8,9%     |

Moltiplicando PAM1 per 2000 (*passi di evoluzione*) si arriva ad una situazione in cui la **probabilità converge alla frequenza osservata**

| Frequenze normalizzate degli amminoacidi |          |  |  |
|------------------------------------------|----------|--|--|
| Ogni quanto occorrono nelle proteine?    |          |  |  |
| Gly 8.9%                                 | Arg 4.1% |  |  |
| Ala 8.7%                                 | Asn 4.0% |  |  |
| Leu 8.5%                                 | Phe 4.0% |  |  |
| Lys 8.1%                                 | Gln 3.8% |  |  |
| Ser 7.0%                                 | Ile 3.7% |  |  |
| Val 6.5%                                 | His 3.4% |  |  |
| Thr 5.8%                                 | Cys 3.3% |  |  |
| Pro 5.1%                                 | Tyr 3.0% |  |  |
| Glu 5.0%                                 | Met 1.5% |  |  |
| Asp 4.7%                                 | Trp 1.0% |  |  |

• blu=6 codoni; rosso=1 codone  
• Le frequenze  $f_i$  si sommano a 1

## Matrice PAM250 (*probabilità*) di mutazione

Aminoacido originale

Aminoacido mutato

|   | A  | R  | N  | D  | C  | Q  | E  | G  | H  | I  | L  | K  | M  | F  | P | S  | T  | W  | Y  | V  |
|---|----|----|----|----|----|----|----|----|----|----|----|----|----|----|---|----|----|----|----|----|
| A | 13 | 6  | 9  | 5  | 8  | 9  | 12 | 6  | 7  | 7  | 4  | 11 | 11 | 11 | 2 | 4  | 9  |    |    |    |
| R | 3  | 17 | 4  | 3  | 2  | 5  | 3  | 2  | 6  | 3  | 2  | 9  | 4  | 1  | 4 | 4  | 3  | 7  | 2  | 2  |
| N | 4  | 4  | 6  | 7  | 2  | 5  | 6  | 4  | 6  | 3  | 2  | 5  | 3  | 2  | 4 | 5  | 4  | 2  | 3  | 3  |
| D | 5  | 4  | 8  | 11 | 1  | 7  | 10 | 5  | 6  | 3  | 2  | 5  | 3  | 1  | 4 | 5  | 5  | 1  | 2  | 3  |
| C | 2  | 1  | 1  | 1  | 52 | 1  | 1  | 2  | 2  | 2  | 1  | 1  | 1  | 1  | 2 | 3  | 2  | 1  | 4  | 2  |
| Q | 3  | 5  | 5  | 6  | 1  | 10 | 7  | 3  | 7  | 2  | 3  | 5  | 3  | 1  | 4 | 3  | 3  | 1  | 2  | 3  |
| E | 5  | 4  | 7  | 11 | 1  | 9  | 12 | 5  | 6  | 3  | 2  | 5  | 3  | 1  | 4 | 5  | 5  | 1  | 2  | 3  |
| G | 12 | 5  | 10 | 10 | 4  | 7  | 9  | 27 | 5  | 5  | 4  | 6  | 5  | 3  | 8 | 11 | 9  | 2  | 3  | 7  |
| H | 2  | 5  | 5  | 4  | 2  | 7  | 4  | 2  | 15 | 2  | 2  | 3  | 2  | 2  | 3 | 3  | 2  | 2  | 3  | 2  |
| I | 3  | 2  | 2  | 2  | 2  | 2  | 2  | 2  | 10 | 6  | 2  | 6  | 5  | 2  | 3 | 4  | 1  | 3  | 9  |    |
| L | 6  | 4  | 4  | 3  | 2  | 6  | 4  | 3  | 5  | 15 | 34 | 4  | 20 | 13 | 5 | 4  | 6  | 7  | 13 |    |
| K | 6  | 18 | 10 | 8  | 2  | 10 | 8  | 5  | 8  | 5  | 4  | 24 | 9  | 2  | 6 | 8  | 8  | 4  | 3  | 5  |
| M | 1  | 1  | 1  | 1  | 0  | 1  | 1  | 1  | 1  | 2  | 3  | 2  | 6  | 2  | 1 | 1  | 1  | 1  | 2  |    |
| F | 2  | 1  | 2  | 1  | 1  | 1  | 1  | 3  | 5  | 6  | 1  | 4  | 32 | 1  | 2 | 2  | 1  | 4  | 20 | 3  |
| P | 7  | 5  | 5  | 4  | 3  | 5  | 4  | 5  | 3  | 3  | 4  | 3  | 2  | 20 | 6 | 5  | 1  | 2  | 4  |    |
| S | 9  | 6  | 8  | 7  | 7  | 6  | 7  | 9  | 6  | 5  | 4  | 7  | 5  | 3  | 9 | 10 | 9  | 4  | 4  | 6  |
| T | 8  | 5  | 6  | 6  | 4  | 5  | 5  | 6  | 4  | 6  | 4  | 6  | 5  | 3  | 6 | 8  | 11 | 2  | 3  | 6  |
| W | 0  | 2  | 0  | 0  | 0  | 0  | 0  | 0  | 1  | 0  | 1  | 0  | 0  | 1  | 0 | 1  | 0  | 55 | 1  | 0  |
| Y | 1  | 1  | 2  | 1  | 3  | 1  | 1  | 1  | 3  | 2  | 2  | 1  | 2  | 15 | 1 | 2  | 3  | 31 | 2  |    |
| V | 7  | 4  | 4  | 4  | 4  | 4  | 4  | 5  | 4  | 15 | 10 | 4  | 10 | 5  | 5 | 5  | 7  | 2  | 4  | 17 |

PAM 250 è un caso interessante: ottenuta da PAM1^250 prevede che circa il 20% della sequenza sia conservato. A->A ha probabilità del 13%. Da notare W e C che anche dopo 250 mutazioni hanno il 50% di probabilità di non mutare.

## Approccio Dayhoff per l'assegnazione di punteggi per ogni due residui di aminoacidi allineati

Dayhoff et al. hanno definito il **punteggio** (score) per due generici residui  $i, j$ :

$q_{i,j}$  = probabilità che l'aminoacido  $i$  venga sostituito da  $j$   
(probabilità di omologia in base alle sostituzioni osservate)

$p_{i,j}$  = Probabilità di trovare casualmente l'appaiamento  $i, j$   
(prodotto della probabilità di trovare un "i" e quella di trovare un "j" in una qualunque sequenza, cioè *prodotto delle frequenze*)

Il loro rapporto serve a tenere conto che l'evento  $q_{i,j}$  sia casuale.

Il valore è poi convertito al log (per rendere due valori sommabili) e moltiplicato per 10 (così che, prendendo la parte intera del valore si conserva la prima cifra decimale). Gli score sono utili negli allineamenti a coppie (e in algoritmi di ricerca come BLAST)

$$S_{i,j} = 10 \times \log \left( \frac{q_{i,j}}{p_{i,j}} \right)$$

## PAM250 log scores Matrice di calcolo

$S(\text{trp, trp}) = 10 \log(0.55/0.010) = 17,4$   
significa che la probabilità di trovare un W conservato è 50 volte maggiore della probabilità che un W sia a caso nelle due posizioni considerate.

Un -10 è un -1(Log) quindi 1/10 e indica che la probabilità che quell'allineamento si verifichi è 1/10 della frequenza di quegli aminoacidi in posizioni corrispondenti.

|   | A  | R  | N  | D  | C  | Q  | E  | G  | H  | I  | L  | K  | M  | F  | P  | S  | T  | W  | Y  | V |
|---|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|---|
| A | 2  |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| R | -2 | 6  |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| N | 0  | 0  | 2  |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| D | 0  | -1 | 2  | 4  |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| C | -2 | -4 | -4 | -5 | 12 |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| Q | 0  | 1  | 1  | 2  | -5 | 4  |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| E | 0  | -1 | 1  | 3  | -5 | 2  | 4  |    |    |    |    |    |    |    |    |    |    |    |    |   |
| G | 1  | -3 | 0  | 1  | -3 | -1 | 0  | 5  |    |    |    |    |    |    |    |    |    |    |    |   |
| H | -1 | 2  | 2  | 1  | -3 | 3  | 1  | -2 | 6  |    |    |    |    |    |    |    |    |    |    |   |
| I | -1 | -2 | -2 | -2 | -2 | -2 | -3 | -2 | 5  |    |    |    |    |    |    |    |    |    |    |   |
| L | -2 | -3 | -3 | -4 | -6 | -2 | -3 | -4 | -2 | 6  |    |    |    |    |    |    |    |    |    |   |
| K | -1 | 3  | 1  | 0  | -5 | 1  | 0  | -2 | 0  | -2 | -3 | 5  |    |    |    |    |    |    |    |   |
| M | -1 | 0  | -2 | -3 | -5 | -1 | -2 | -3 | -2 | 2  | 4  | 0  | 6  |    |    |    |    |    |    |   |
| F | -3 | -4 | -3 | -6 | -4 | -5 | -5 | -5 | -2 | 1  | 2  | -5 | 0  | 9  |    |    |    |    |    |   |
| P | 1  | 0  | 0  | -1 | -3 | 0  | -1 | 0  | 0  | -2 | -3 | -1 | -2 | -5 | 6  |    |    |    |    |   |
| S | 1  | 0  | 1  | 0  | 0  | -1 | 0  | 1  | -1 | -1 | -3 | 0  | -2 | -3 | 1  | 2  |    |    |    |   |
| T | 1  | -1 | 0  | 0  | -2 | -1 | 0  | 0  | -1 | 0  | -2 | 0  | -1 | -3 | 0  | 1  | 7  |    |    |   |
| W | -6 | 2  | -4 | -7 | -8 | -5 | -7 | -7 | -3 | -5 | -2 | -3 | -4 | 0  | -6 | -2 | -5 | 17 |    |   |
| Y | -3 | -4 | -2 | -4 | 0  | -4 | -4 | -5 | 0  | -1 | -1 | -4 | -2 | 7  | -5 | -3 | -3 | 0  | 10 |   |
| V | 0  | -2 | -2 | -2 | 0  | -2 | -2 | -1 | -2 | 4  | 2  | -2 | 2  | -1 | -1 | 0  | -6 | -2 | 4  |   |
| A |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| R |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| N |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| D |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| C |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| Q |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| E |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| G |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| H |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| I |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| L |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| K |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| M |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| F |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| P |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| S |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| T |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| W |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| Y |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |
| V |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |

## Matrici PAM a confronto


| PAM250 | PAM100 | PAM30 |
|--------|--------|-------|
| A      | A      | A     |
| R      | R      | R     |
| N      | N      | N     |
| D      | D      | D     |
| C      | C      | C     |
| Q      | Q      | Q     |
| E      | E      | E     |
| G      | G      | G     |
| H      | H      | H     |
| I      | I      | I     |
| L      | L      | L     |
| K      | K      | K     |
| M      | M      | M     |
| F      | F      | F     |
| P      | P      | P     |
| S      | S      | S     |
| T      | T      | T     |
| W      | W      | W     |
| Y      | Y      | Y     |
| V      | V      | V     |

PAM250

PAM100

PAM30

-17 +17



## Matrici BLOSUM

Le matrici **BLOSUM** sono basate su *allineamenti locali*, tratti dal database BLOCKS che raggruppa **blocchi (regioni)** di *allineamenti locali* di sequenze *lontanamente correlate*.


BLOSUM sta per **BLO**ck **SU**stitution **M**atrix.

BLOSUM62 è una matrice calcolata a partire da sequenze con divergenza minore del 62%. **Default per BLAST.**


Il metodo di calcolo degli score è poi simile a quello per le PAM, ma si usa  $\lambda=2$  al posto di 10 (infatti per BLOSUM il range è 90-45 VS 30-250 per le PAM)

$$S_{ij} = \left( \frac{1}{\lambda} \right) \log \left( \frac{p_{ij}}{q_i * q_j} \right)$$


## Matrici BLOSUM



## Matrici BLOSUM



|   |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |    |    |   |
|---|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|---|----|----|---|
| A | 4  |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |    |    |   |
| R | -1 | 5  |    |    |    |    |    |    |    |    |    |    |    |    |    |    |   |    |    |   |
| N | -2 | 0  | 6  |    |    |    |    |    |    |    |    |    |    |    |    |    |   |    |    |   |
| D | -2 | -2 | 1  | 6  |    |    |    |    |    |    |    |    |    |    |    |    |   |    |    |   |
| C | 0  | -3 | -3 | -3 | 9  |    |    |    |    |    |    |    |    |    |    |    |   |    |    |   |
| Q | -1 | 1  | 0  | 0  | -3 | 5  |    |    |    |    |    |    |    |    |    |    |   |    |    |   |
| E | -1 | 0  | 0  | 2  | -4 | 2  | 5  |    |    |    |    |    |    |    |    |    |   |    |    |   |
| G | 0  | -2 | 0  | -1 | -3 | -2 | -2 | 6  |    |    |    |    |    |    |    |    |   |    |    |   |
| H | -2 | 0  | 1  | -1 | -3 | 0  | 0  | -2 | 8  |    |    |    |    |    |    |    |   |    |    |   |
| I | -1 | -3 | -3 | -3 | -1 | -3 | -3 | -4 | -3 | 4  |    |    |    |    |    |    |   |    |    |   |
| L | -1 | -2 | -3 | -4 | -1 | -2 | -3 | -4 | -3 | 2  | 4  |    |    |    |    |    |   |    |    |   |
| K | -1 | 2  | 0  | -1 | -1 | 1  | 1  | -2 | -1 | -3 | -2 | 5  |    |    |    |    |   |    |    |   |
| M | -1 | -2 | -2 | -3 | -1 | 0  | -2 | -3 | -2 | 1  | 2  | -1 | 5  |    |    |    |   |    |    |   |
| F | -2 | -3 | -3 | -3 | -2 | -3 | -3 | -3 | -1 | 0  | 0  | -3 | 0  | 6  |    |    |   |    |    |   |
| P | -1 | -2 | -2 | -1 | -3 | -1 | -1 | -2 | -2 | -3 | -3 | -1 | -2 | -4 | 7  |    |   |    |    |   |
| S | 1  | -1 | 1  | 0  | -1 | 0  | 0  | 0  | -1 | -2 | -2 | 0  | -1 | -2 | -1 | 4  |   |    |    |   |
| T | 0  | -1 | 0  | -1 | -1 | -1 | -1 | -2 | -2 | -1 | -1 | -1 | -2 | -1 | 1  | 5  |   |    |    |   |
| W | -3 | -3 | -4 | -4 | -2 | -2 | -3 | -2 | -2 | -3 | -1 | 1  | -4 | -3 | -2 | 11 |   |    |    |   |
| Y | -2 | -2 | -2 | -3 | -2 | -1 | -2 | -3 | 2  | -1 | -2 | -1 | 3  | -3 | -2 | -2 | 2 |    |    |   |
| V | 0  | -3 | -3 | -3 | -1 | -2 | -2 | -3 | -3 | 3  | 1  | -2 | 1  | -1 | -2 | -2 | 0 | -3 | -1 | 4 |
|   | A  | R  | N  | D  | C  | Q  | E  | G  | H  | I  | L  | K  | M  | F  | P  | S  | T | W  | Y  | V |



Percentuale di identità

"Twilight Zone"

250

Differenza per 100 residui